

BÁO CÁO PHÂN TÍCH SỰ THAM GIA CỦA NGƯỜI DÙNG TRÊN TWITTER

Học phần Thực hành Trực quan hóa dữ liệu

Nhóm 1

Khuất Thanh Phương, Lê Tuấn Thành, Vũ Quang Huy, Đậu Thị Thảo, Vũ Như An

I. LỜI MỞ ĐẦU

Trong thời đại số, mạng xã hội X (Twitter) là một trong những ứng dụng phổ biến nhất để người dùng có thể tương tác với nhau. Báo cáo này nhằm phân tích mức độ, khả năng tương tác của người dùng với nhau trên nền tảng này. Nhóm sử dụng bộ dữ liệu "Twitterdatainsheets.csv" trên trang web Kaggle.

II. NỘI DUNG

A. Chuẩn bị và khám phá dữ liệu

Bộ dữ liệu chứa 206.295 bản ghi và 14 trường cung cấp thông tin toàn diện về các tweet và tương tác của người dùng trên nền tảng mạng xã hội phổ biến Twitter giúp làm sáng tỏ các đặc điểm và số liệu đo lường mức độ tương tác của tweet, cho phép phân tích chuyên sâu về hành vi người dùng và hiệu suất nội dung.

Tên biến	Mô tả
TweetID	Mã bài đăng (phân loại)
Weekday	Ngày trong tuần (phân loại)
Hour	giờ trong ngày tweet được đăng (phân loại)
Day	Ngày cụ thể mà tweet được đăng
Lang	Ngôn ngữ được sử dụng để viết tweet. (Phân loại)
IsReshare	Chỉ ra liệu tweet có được chia sẻ lại hay không. (Boolean)
Reach	Phạm vi tiếp cận: Số lượng người dùng duy nhất đã nhìn thấy tweet.
RetweetCount	Số lần tweet được retweet
Likes	Số lượt thích mà tweet nhận được.
Klout	Điểm Klout của người dùng đã đăng tweet, thể hiện tầm ảnh hưởng xã hội của họ
Sentiment	Cảm xúc của dòng tweet, cho biết liệu nó là tích cực, tiêu cực hay trung lập. (Phân loại)
text	Nội dung của tweet (định tính)
LocationID	Mã định danh vùng địa lý (địa điểm tweet được đăng hoặc người dùng ở đó)
UserID	Mã định danh người dùng đăng tweet

Bảng I: Bảng thuộc tính

B. Phân tích dữ liệu thăm dò (EDA)

Dữ liệu bị lỗi từ dòng 100.000 cần được loại bỏ. Sau khi loại bỏ 106.295 bản ghi, dữ liệu còn lại 100.000 bản ghi hợp lệ không chứa giá trị thiếu và không có giá trị ngoại lệ bất thường. Chuẩn hóa

cột "Hour", loại khoảng trắng và đưa về số nguyên. Làm sạch cột 'text' nâng cao, xóa các URL, các ký tự không phải chữ. Xóa các biểu tượng cảm xúc nếu có.

Mức độ tương quan giữa các chỉ số với điểm Klout: Reach có tương quan dương yếu với Klout,


	Klout
Hour	-0.000182
Day	0.014898
Reach	0.196436
RetweetCount	-0.021488
Likes	0.135159
Sentiment	-0.007172
LocationID	0.096458

Bảng II: Bảng hệ số tương quan giữa các chỉ số với điểm Klout

cho thấy khi mức độ tiếp cận tăng, điểm Klout có xu hướng tăng nhẹ. Khả năng lan truyền của tài khoản có ảnh hưởng nhất định đến uy tín hoặc sức ảnh hưởng (Klout). Likes và LocationID cũng có tương quan dương yếu, tức là người dùng nhận nhiều lượt thích hơn hoặc từ một số khu vực nhất định có thể có điểm Klout cao hơn, tuy nhiên không mạnh. RetweetCount, Sentiment có tương quan gần như bằng 0, nghĩa là hầu như không có mối liên hệ tuyến tính đáng kể với Klout.

C. Trực quan hóa dữ liệu


Vùng mật độ cao nhất tập trung ở khoảng độ dài tweet từ 100–250 ký tự và điểm Klout 30–60 cho thấy phần lớn người dùng có ảnh hưởng trung bình viết tweet có độ dài vừa phải. Ở các mức Klout cao >80, mật độ điểm rất thưa, chứng tỏ người có ảnh hưởng cao chiếm tỷ lệ nhỏ trong toàn bộ mẫu dữ liệu. Không thấy xu hướng tăng rõ ràng của Klout theo độ dài tweet. Các điểm phân bố khá rải rác chứng tỏ độ dài nội dung không phải yếu tố quyết định đến mức độ ảnh hưởng. Một vài điểm ngoại lệ



Hình 1: Mối quan hệ giữa Độ dài Tweet, Klout và Mức độ tương tác

xuất hiện ở độ dài >600 ký tự, nhưng hiếm, có thể do các tweet là chuỗi tweet hoặc nội dung quảng bá.


Nhóm Klout trung bình có số lượng tweet cao nhất và phân bố tập trung ở độ dài khoảng 100–250 ký tự, cho thấy đây là độ dài phổ biến nhất của người dùng có ảnh hưởng vừa phải. Nhóm Klout thấp có xu hướng tương tự nhưng mật độ thấp hơn, thể hiện rằng người ảnh hưởng thấp vẫn viết tweet với độ dài gần giống nhóm trung bình, chỉ khác về tần suất đăng hoặc tương tác. Nhóm Klout cao xuất hiện rất ít, cho thấy người có ảnh hưởng lớn chiếm tỷ lệ nhỏ trong tổng mẫu. Nhìn chung, không có sự khác biệt đáng kể về độ dài giữa các nhóm, chứng minh rằng độ dài tweet không phải yếu tố quyết định đến điểm Klout mà thay vào đó, yếu tố nội dung và tương tác quan trọng hơn.



Hình 2: Top 10 LocationID xuất hiện nhiều nhất

LocationID 3751.0 dẫn đầu với 7004 tweet, gấp hơn 5 lần so với vị trí thứ 5 trở xuống. Có sự chênh lệch lớn giữa top 3 (3751.0, 3019.0, 3753.0 có từ 4000-7000 tweet) với các vị trí còn lại chỉ dao động 1200-2600 tweet, cho thấy hoạt động tweet tập trung mạnh ở một số vùng hoặc quốc gia nhất định.

Biểu đồ top 20 từ xuất hiện nhiều nhất cho thấy sau khi loại bỏ các stopwords, các từ khóa nổi bật




Hình 3: Top 20 từ xuất hiện nhiều nhất

phản ánh rõ hơn chủ đề chính của dữ liệu. Trong đó, “aws” tiếp tục dẫn đầu với hơn 64.000 lần xuất hiện, khẳng định sự thống trị của chủ đề Amazon Web Services trong tập tweet. Các từ như “amazon”, “cloud”, “services”, “web”, và “lambda” cũng xuất hiện nhiều, cho thấy phần lớn các tweet tập trung vào lĩnh vực công nghệ, đặc biệt là các dịch vụ đám mây và lập trình AWS. Ngoài ra, các từ như “engineer”, “data”, “azure”, và “hiring” gợi ý rằng nhiều tweet liên quan đến tuyển dụng, học tập và chia sẻ kiến thức kỹ thuật, phản ánh sự sôi động của cộng đồng công nghệ trên Twitter




Hình 4: WordCloud từ văn bản Twitter



Hình 5: Phân bố hoạt động theo giờ


Hoạt động tăng nhanh từ rạng sáng, đạt đỉnh

khoảng 10–11h rồi giảm dần sau trưa. Khung giờ sôi động từ 8–12h (cao nhất) và giữ mức khá tới 15–16h. Thấp nhất vào đêm muộn/đầu sáng (22–5h), hạn chế đăng nếu muốn tương tác cao.



Hình 6: Số lượt Likes trung bình theo giờ


Lượt thích tăng mạnh từ sáng và đạt đỉnh lúc 16:00 (0.34 like/tweet), sau đó giảm nhanh về tối. Khung giờ hiệu quả: 11:00–17:00 (đặc biệt 15–16h có mức cao nhất). Thấp nhất vào rạng sáng (0–6h) và giảm sâu sau 20h → hạn chế đăng nếu cần nhiều like.



Hình 7: Trung bình ReTweetCount theo giờ


Lượt retweet trung bình tăng dần từ sau 18h và đạt đỉnh khoảng 23:00 (11.5). Ban ngày khoảng 10–17h mức retweet thấp hơn và khá ổn định quanh 6–7. Nếu mục tiêu là tối đa hóa retweet, đăng bài vào buổi tối (19–23h) sẽ hiệu quả hơn rạng sáng/ban ngày.

Biểu đồ cho thấy trong nhóm Tweet tích cực, các từ khóa nổi bật nhất là “aws”, “amazon”, “cloud” và “services”, phản ánh rõ ràng chủ đề trung tâm



Hình 8: Top 10 từ tích cực xuất hiện nhiều nhất


xoay quanh các sản phẩm và dịch vụ công nghệ của Amazon Web Services. Sự xuất hiện của các từ như “free”, “learn” và “join” cho thấy nhiều Tweet mang tính khuyến khích học tập, chia sẻ cơ hội hoặc quảng bá sự kiện công nghệ, thể hiện thái độ tích cực và sự hứng thú của cộng đồng người dùng đối với lĩnh vực công nghệ đám mây.



Hình 9: Top 10 từ tiêu cực xuất hiện nhiều nhất

Biểu đồ cho thấy trong nhóm Tweet tiêu cực, các từ khóa nổi bật vẫn xoay quanh “aws”, “cloud”, và “amazon”, nhưng xuất hiện thêm các từ như “cuts”, “prices”, và “microsoft”. Điều này cho thấy người dùng có xu hướng bày tỏ sự không hài lòng hoặc lo ngại về các vấn đề như cắt giảm nhân sự, thay đổi giá dịch vụ hoặc cạnh tranh giữa các hãng công nghệ lớn. Tổng thể, nội dung tiêu cực tập trung vào khía cạnh kinh tế và thị trường trong lĩnh vực điện toán đám mây.

Biểu đồ cho thấy các Tweet trung tính chủ yếu đề cập đến “aws”, “amazon”, “services”, và “cloud”, cho thấy nội dung phần lớn liên quan đến các thông tin, cập nhật hoặc chia sẻ kỹ thuật về công nghệ đám mây của Amazon Web Services. Sự xuất hiện



Hình 10: Top 10 từ trung tính xuất hiện nhiều nhất

của các từ như “engineer”, “lambda”, và “data” phản ánh rằng nhiều Tweet mang tính chia sẻ kiến thức hoặc thảo luận chuyên môn, không mang sắc thái cảm xúc rõ rệt.

III. KẾT LUẬN

Qua quá trình xử lý và phân tích 100.000 Tweet, báo cáo đã làm rõ bức tranh toàn diện về cảm xúc, hành vi và xu hướng tương tác của người dùng trên Twitter. Phần lớn các Tweet tập trung vào lĩnh vực công nghệ, đặc biệt là Amazon Web Services (AWS), thể hiện mức độ quan tâm lớn của cộng đồng mạng đối với các chủ đề về điện toán đám mây và đổi mới kỹ thuật. Kết quả phân tích cho thấy các Tweet mang cảm xúc tích cực chiếm ưu thế, thường dùng để chia sẻ kiến thức, quảng bá sự kiện hoặc thể hiện sự hài lòng với sản phẩm, trong khi các Tweet tiêu cực tập trung phản ánh vấn đề về giá cả hoặc cạnh tranh giữa các doanh nghiệp công nghệ. Nhóm trung tính chủ yếu mang tính thông tin và cập nhật kỹ thuật. Bên cạnh đó, mối liên hệ giữa độ dài bài viết, điểm ảnh hưởng (Klout) và mức độ tương tác (Likes, Retweets) cho thấy những người dùng có tầm ảnh hưởng thường đăng tải nội dung ngắn gọn, súc tích nhưng có sức lan tỏa cao. Kết quả nghiên cứu khẳng định vai trò quan trọng của phân tích dữ liệu và xử lý ngôn ngữ tự nhiên trong việc hiểu rõ hơn cách người dùng thể hiện cảm xúc, đồng thời cung cấp nền tảng hữu ích cho các tổ chức, doanh nghiệp trong việc hoạch định chiến lược truyền thông, tiếp thị và quản trị hình ảnh trên không gian mạng.