

BÁO CÁO

SO SÁNH MỨC ĐỘ VIRAL GIỮA WORLD CUP 2022 VÀ OLYMPIC 2024

Khuất Thanh Phương, Bùi Đăng Danh, Lê Tuấn Thành

I. GIỚI THIỆU VÀ QUY TRÌNH TỔNG QUAN

Phân tích dữ liệu văn bản là quá trình trích xuất thông tin có ý nghĩa từ dữ liệu phi cấu trúc. Các đơn vị phân tích được tổ chức theo các giai đoạn tuần tự nhằm chuyển đổi dữ liệu thô thành các kết quả định lượng và định tính.

Các giai đoạn phân tích chính: Quy trình được chia thành ba giai đoạn chính, áp dụng độc lập cho từng tập dữ liệu (World Cup 2022 hoặc Olympics 2024):

- Tiền xử lý dữ liệu (Data Preprocessing):** Làm sạch và chuẩn hóa văn bản.
- Phân tích Từ vựng và Nội dung (Lexical & Content Analysis):** Trích xuất đặc trưng và chủ đề.
- Phân tích Cảm xúc và Thời gian (Sentiment & Temporal Analysis):** Đánh giá sắc thái và xu hướng theo thời gian.

II. QUY TRÌNH PHÂN TÍCH

2.1. Giới thiệu bộ dữ liệu

Hai bộ dữ liệu được sử dụng trong nghiên cứu gồm “olympics2024_youtube.csv” và “worldcup2022_youtube.csv”, đều được thu thập từ nền tảng **YouTube** nhằm phân tích mức độ phổ biến và tương tác của các video liên quan đến hai sự kiện thể thao lớn nhất thế giới là **Thế vận hội Olympic Paris 2024** và **Giải bóng đá World Cup 2022 tại Qatar**.

Bộ dữ liệu **Olympic 2024** gồm **100 video** với **9 biến** chính: video_id, title, channel, publishedAt, duration, viewCount, likeCount, commentCount, và link. Các biến này thể hiện thông tin chi tiết của từng video như tiêu đề, kênh đăng tải, thời gian công bố, độ dài, lượng xem, lượt thích và bình luận. Dữ liệu có **3 giá trị bị thiếu**, cho thấy chất lượng dữ liệu tương đối tốt và sẵn sàng cho các bước phân tích tiếp theo.

Tương tự, bộ dữ liệu **World Cup 2022** cũng bao gồm **100 video** và **9 biến** với cấu trúc giống bộ dữ liệu Olympic. Tuy nhiên, bộ dữ liệu này có **6 giá trị bị thiếu**, cần được xử lý trước khi tiến hành phân tích. Việc khai thác hai bộ dữ liệu này giúp đánh giá **hiệu quả truyền thông và mức độ tương tác của khán giả toàn cầu** đối với các sự kiện thể thao quốc tế, qua đó rút ra nhận định về **sức ảnh hưởng của nội dung thể thao trên nền tảng số**.

Bảng 1: Phân nhóm các đặc trưng của hai bộ dữ liệu YouTube (Olympics 2024 và World Cup 2022)

Nhóm đặc trưng	Các biến thuộc nhóm	Ý nghĩa và chức năng
1. Nhóm nhận dạng (Identification Features)	video_id, link	Dùng để định danh duy nhất mỗi video và liên kết đến nguồn gốc trên YouTube. Giúp tránh trùng lặp dữ liệu và đảm bảo tính toàn vẹn thông tin.
2. Nhóm nội dung (Content Features)	title, channel, duration	Phản ánh nội dung video, đơn vị đăng tải và độ dài video. Là cơ sở cho phân tích văn bản, phân loại chủ đề và đánh giá độ ảnh hưởng của kênh.
3. Nhóm thời gian (Temporal Feature)	publishedAt	Ghi nhận thời điểm đăng tải video, phục vụ cho việc phân tích xu hướng theo thời gian và mức độ lan tỏa trước, trong, sau sự kiện.
4. Nhóm tương tác (Engagement Features)	viewCount, likeCount, commentCount	Thể hiện mức độ quan tâm và tương tác của người xem: số lượt xem, lượt thích và bình luận. Đây là nhóm biến quan trọng phản ánh hiệu quả truyền thông.

2.2. Tiền xử lý dữ liệu

2.2.1. Làm sạch và chuẩn hóa dữ liệu.

Sau khi dữ liệu được làm sạch và chuẩn hóa định dạng, quá trình xử lý văn bản được thực hiện nhằm chuẩn bị cho bước phân tích cảm xúc và trực quan hóa. Các bước cụ thể như sau:

- Chuyển đổi sang chữ thường (Lowercasing):** Tất cả ký tự trong tiêu đề được đưa về dạng chữ thường nhằm đảm bảo tính nhất quán và tránh xem các từ giống nhau nhưng khác kiểu chữ (như “Word” và “word”) là khác biệt.
- Loại bỏ URL:** Mọi đường dẫn web trong nội dung được loại bỏ bằng biểu thức chính quy để tránh nhiễu trong dữ liệu.
- Loại bỏ ký tự đặc biệt:** Chỉ giữ lại các ký tự chữ cái từ a-z, chữ số từ 0-9 và dấu thăng (“#”) bằng biểu thức chính quy
- Tách từ (Tokenization):** Văn bản được tách thành các *token* riêng lẻ bằng hàm `nltk.tokenize.word_tokenize()`, giúp thuận tiện cho phân tích tần suất và ý nghĩa từ vựng.
- Loại bỏ từ dừng (Stopwords):** Các từ phổ biến nhưng ít đóng góp về mặt ngữ nghĩa (ví dụ: “a”, “the”, “is”, “and”) được loại bỏ dựa trên danh sách `nltk.corpus.stopwords`.
- Chuẩn hóa từ (Stemming / Lemmatization):** Các biến thể của cùng một từ (ví dụ: *playing*, *played*) được đưa về dạng gốc (*play*) nhằm giảm độ phân tán từ vựng.
- Kết hợp lại (Reconstruction):** Các token còn lại sau xử lý được nối lại thành một chuỗi duy nhất, tạo thành tiêu đề sạch và được lưu trong trường `cleaned_title`.

Quy trình trên giúp chuẩn hóa nội dung văn bản, giảm nhiễu và nâng cao độ chính xác cho các bước phân tích cảm xúc và trực quan hóa dữ liệu sau này.

2.2.2. Tách từ và loại bỏ Stop Words (Tokenization Stopwords Removal)

- Tokenization:** Phân tách văn bản thành các đơn vị nhỏ (tokens).
- Stopwords Removal:** Xóa các từ dừng (ví dụ: “và”, “của”, “the”, “is”).
- Stemming/Lemmatization:** Chuẩn hóa từ về dạng gốc để giảm đa dạng từ vựng.

2.3. Phân tích từ vựng và nội dung

2.3.1. Thống kê từ vựng cơ bản (Basic Lexical Statistics).

Bảng 2: So sánh đặc trưng ngôn ngữ giữa hai bộ dữ liệu World Cup 2022 và Olympics 2024

Sự kiện	Tổng số Token	Kích thước từ vựng
Olympics 2024	1 050	428
World Cup 2022	996	315

Ghi chú: Token là tổng số đơn vị từ trong văn bản; kích thước từ vựng là số lượng từ duy nhất xuất hiện trong tập dữ liệu. Tỷ lệ Type-Token (TTR) của Olympics 2024 đạt 0.4076 cho thấy mức độ đa dạng từ vựng cao, trong khi World Cup 2022 có TTR = 0.3163 thể hiện tần suất lặp từ cao hơn.


2.3.2. Phân tích tần suất (Frequency Analysis).

- Top N từ khóa:** Danh sách từ xuất hiện nhiều nhất.
- Tần suất Hashtag:** Phản ánh xu hướng và chủ đề phổ biến.
- N-gram Analysis:** Phân tích các cụm từ (bigram, trigram) quan trọng.

Bảng 3: Bảng Tần suất Từ khóa/Hashtag Nổi bật


Từ khóa/Hashtag	Số lần xuất hiện
#worldcup	1587
#paris2024	920
highlights	710
music	650
race	480

2.3.3. Trực quan hóa nội dung.




Hình 1: Mức độ đăng tải video theo hàng ngày.

Biểu đồ thể hiện mật độ đăng tải video liên quan đến hai sự kiện thể thao theo thời gian. Dễ thấy, World Cup 2022 (đường đỏ) đạt đỉnh vào cuối năm 2022 – đầu 2023, trùng với giai đoạn giải đấu diễn ra, sau đó giảm dần. Trong khi đó, Olympics 2024 (đường xanh) có mức tăng mạnh và đạt đỉnh rõ rệt vào giữa năm 2024, cho thấy lượng nội dung bùng nổ trong thời điểm Thế vận hội Paris diễn ra, phản ánh sự quan tâm lớn từ công chúng và truyền thông.




Hình 2: Xu hướng đăng tải video theo tháng - World Cup 2022.

Biểu đồ thể hiện xu hướng đăng tải video liên quan đến World Cup 2022 theo từng tháng. Dễ thấy, lượng video tăng đột biến vào tháng 12/2022, trùng với giai đoạn giải đấu diễn ra tại Qatar, sau đó nhanh chóng giảm mạnh khi sự kiện kết thúc. Từ năm 2023 trở đi, số lượng video duy trì ở mức thấp và ổn định, cho thấy mức độ quan tâm giảm dần sau khi giải đấu kết thúc.




Hình 3: Xu hướng đăng tải video theo tháng - Olympic 2024.

Biểu đồ thể hiện xu hướng đăng tải video liên quan đến Olympics 2024 theo từng tháng. Dữ liệu cho thấy số lượng video tăng mạnh từ giữa năm 2024 và đạt đỉnh vào tháng 8/2024, trùng với thời điểm Thế vận hội Paris diễn ra. Sau khi sự kiện kết thúc, lượng video giảm nhanh và duy trì ở mức rất thấp, phản ánh chu kỳ quan tâm ngắn hạn tập trung chủ yếu trong giai đoạn tổ chức Thế vận hội.




Hình 4: Mức độ tương tác trung bình hàng tháng của 2 sự kiện.

Biểu đồ cho thấy mức độ tương tác trung bình hàng tháng giữa hai sự kiện thể thao lớn — World Cup 2022 và Olympics 2024. Kết quả cho thấy World Cup 2022 có mức tương tác vượt trội, đạt đỉnh hơn 140 triệu lượt xem trung bình vào cuối năm 2022, trùng với thời điểm giải đấu diễn ra. Trong khi đó, Olympics 2024 duy trì mức tương tác ổn định và thấp hơn nhiều, thể hiện rằng World Cup thu hút lượng quan tâm và thảo luận trực tuyến lớn hơn đáng kể. Sau giai đoạn cao điểm, cả hai sự kiện đều cho thấy sự suy giảm tương tác rõ rệt.




Hình 5: Tổng lượt xem trung bình hàng ngày theo thời gian (2025).

Biểu đồ này cho thấy lượt xem của "World Cup 2025"(đường màu xanh) biến động rất mạnh, với một đỉnh tăng vọt đột biến lên trên 17.5 triệu lượt xem vào khoảng cuối tháng 3. Ngược lại, "Olympics 2025"(đường màu cam) có tổng lượt xem thấp hơn đáng kể nhưng lại duy trì mức độ ổn định hơn nhiều trong suốt cả năm.



Hình 6: Tổng lượt bình luận hàng ngày theo thời gian (2025).

Tương tự như biểu đồ lượt xem, lượng bình luận cho "World Cup 2025" (đường màu xanh) cực kỳ biến động, với hai đợt bùng nổ thảo luận rất lớn vào cuối tháng 3 (hơn 2000 bình luận) và đầu tháng 6 (gần 2500 bình luận). Ngược lại, "Olympics 2025" (đường màu cam) có lượng bình luận thấp hơn nhiều nhưng ổn định hơn, với mức cao nhất chỉ đạt khoảng 400 bình luận vào tháng 8.



Hình 7: Top 15 Hashtags - World Cup 2022.

Biểu đồ trên thể hiện Top 15 từ khóa và hashtag phổ biến nhất trong dữ liệu liên quan đến World Cup 2022. Kết quả cho thấy từ khóa "world" chiếm tần suất cao nhất, theo sau là "argentina", "vs", "football" và "messi" — phản ánh tâm điểm thảo luận xoay quanh trận chung kết giữa Argentina và Pháp, cùng biểu tượng Messi. Các từ như "final", "goal", "highlights", "penalty" cho thấy người dùng tập trung vào các nội dung tường thuật và khoảnh khắc nổi bật của giải đấu.



Hình 15: Word Cloud World Cup 2022
Word Cloud trong hình thể hiện rõ trong tâm nội dung xoay quanh **World Cup 2022**, với các từ khóa nổi bật như **“WORLD”**, **“CUP”**, **“FOOTBALL”**, **“FINAL”**, **“MESSI”**, **“ARGENTINA”** xuất hiện với kích thước lớn — biểu thị tần suất xuất hiện cao trong tập dữ liệu.



Hình 16: Word Cloud Olympics 2024
Các từ khóa lớn như **“GOLD”**, **“OLYMPIC”**, **“PARIS 2024”**, **“FINAL”**, và **“MEDAL”** phản ánh trọng tâm nội dung xoay quanh chủ đề **thành tích, huy chương và sự kiện thể thao quốc tế lớn nhất hành tinh**. Những từ khóa khác như **“SIMONE BILES”**, **“ATHLETICS”**, **“WOMENS”**, **“TEAMUSA”**, và **“INDIA”** cho thấy sự đa dạng về quốc gia, vận động viên và bộ môn được quan tâm.


2.4. Đơn vị phân tích cảm xúc và thời gian.

- **Phương pháp:** Dùng mô hình từ điển (VADER) hoặc học máy để đánh giá điểm cảm xúc.
- **Phân loại:** Positive, Negative, Neutral.
- **Phân phối:** Tỷ lệ phần trăm từng loại trong tập dữ liệu.


Bảng 4: Tỷ lệ cảm xúc giữa Olympics 2024 và World Cup 2022

Loại cảm xúc	Olympics 2024 (%)	World Cup 2022 (%)
Tiêu cực	15.0	24.0
Trung tính	9.0	7.0
Tích cực	76.0	69.0

Tỷ lệ Cảm xúc trong Bình luận - Olympics 2024



Tỷ lệ Cảm xúc trong Bình luận - World Cup 2022



Hình 17: Biểu đồ Phân phối Cảm xúc World Cup 2022 và Olympic 2024

Biểu đồ thể hiện tỷ lệ cảm xúc trong bình luận về hai sự kiện thể thao lớn là **Olympics 2024** và **World Cup 2022** cho thấy nhìn chung, cảm xúc tích cực chiếm ưu thế rõ rệt ở cả hai. Tuy nhiên, tỷ lệ bình luận tích cực đối với Olympics 2024 đạt **76%**, cao hơn 7 điểm phần trăm so với World Cup 2022 (**69%**), phản ánh hình ảnh và không khí của kỳ Thế vận hội được đánh giá tích cực hơn. Trong khi đó, bình luận tiêu cực về World Cup 2022 chiếm **24%**, cao hơn đáng kể so với **15%** ở Olympics 2024, cho thấy sự kiện bóng đá này vấp phải nhiều ý kiến trái chiều hơn. Cảm xúc trung tính ở cả hai sự kiện đều chiếm tỷ lệ thấp (khoảng 7–9%), thể hiện rằng phần lớn người dùng có thái độ rõ ràng khi bình luận. Như vậy, có thể kết luận rằng **Olympics 2024 nhận được phản ứng tích cực và đồng thuận cao hơn**, trong khi **World Cup 2022 tạo ra nhiều tranh luận và cảm xúc trái chiều hơn từ cộng đồng mạng**.

III. ĐÁNH GIÁ RỦI RO VÀ TÍNH PHÁP LÝ

Phân tích các rủi ro tiềm ẩn (dữ liệu không cân bằng, bot spam, giới hạn API) và các yếu tố pháp lý (tuân thủ ToS, ẩn danh PII, không thu thập tin nhắn riêng) liên quan đến việc phân tích dữ liệu bình luận YouTube.

3.1. Các rủi ro tiềm ẩn

Khi thu thập và phân tích dữ liệu bình luận YouTube, có một số rủi ro tiềm ẩn có thể ảnh hưởng đến chất lượng và tính đại diện của nghiên cứu:

- **Dữ liệu không cân bằng (Data Imbalance):**
 - **Mô tả:** Một số video có thể thu hút lượng bình luận lớn hơn đáng kể so với các video khác, hoặc một số chủ đề/sentiment có thể chiếm ưu thế quá mức. Ví dụ, một video gây tranh cãi có thể có nhiều bình luận tiêu cực, trong khi một video quảng cáo có thể có nhiều bình luận tích cực được kiểm duyệt. Sự mất cân bằng này có thể dẫn đến việc mô hình phân tích (ví dụ: sentiment analysis, topic modeling) bị lệch, không phản ánh đúng bức tranh chung hoặc quá nhấn mạnh vào một khía cạnh cụ thể.
 - **Ý nghĩa:** Kết quả phân tích có thể không đáng tin cậy hoặc không thể khái quát hóa cho toàn bộ dữ liệu. Cần có các kỹ thuật xử lý mất cân bằng dữ liệu (như lấy mẫu, trọng số) hoặc nhận thức rõ về giới hạn này khi diễn giải kết quả.
- **Bình luận từ bot hoặc spam (Bot/Spam Comments):**
 - **Mô tả:** YouTube, giống như nhiều nền tảng trực tuyến khác, thường xuyên bị ảnh hưởng bởi các bình luận tự động từ bot hoặc các bình luận spam không liên quan. Những bình luận này có thể bao gồm quảng cáo, liên kết độc hại, hoặc các tin nhắn lặp đi lặp lại nhằm thao túng tương tác hoặc truyền bá thông tin sai lệch.
 - **Ý nghĩa:** Sự hiện diện của bot/spam làm giảm chất lượng dữ liệu, gây nhiễu cho phân tích sentiment và topic modeling. Chúng có thể làm sai lệch kết quả, khiến một số từ khóa hoặc chủ đề không có ý nghĩa xuất hiện nổi bật. Cần có các bước lọc hoặc phát hiện bot/spam trong quá trình tiền xử lý dữ liệu.
- **Giới hạn kỹ thuật từ API YouTube (API Limits):**
 - **Mô tả:** YouTube Data API có các giới hạn về số lượng yêu cầu (quota) mà một ứng dụng có thể thực hiện trong một khoảng thời gian nhất định. Điều này có thể hạn chế số lượng bình luận tối đa mà ta có thể thu thập cho mỗi video hoặc tổng số video mà ta có thể phân tích, đặc biệt đối với các video có hàng ngàn hoặc hàng triệu bình luận.
 - **Ý nghĩa:** Việc không thể thu thập đầy đủ dữ liệu (ví dụ: chỉ lấy được 100 bình luận đầu tiên trong số 10,000 bình luận) có thể dẫn đến mẫu dữ liệu không đại diện. Các bình luận cũ hơn hoặc ít tương tác hơn có thể bị bỏ qua, dẫn đến một góc nhìn sai lệch về xu hướng và cảm xúc tổng thể. Điều này cũng ảnh hưởng đến khả năng mở rộng nghiên cứu nếu cần phân tích lượng dữ liệu lớn hơn.

3.2. Các yếu tố pháp lý

- **Tuân thủ Điều khoản dịch vụ (ToS) của YouTube:**
 - **Mô tả:** Bất kỳ ai sử dụng YouTube Data API đều phải tuân thủ Điều khoản dịch vụ của YouTube và Google. Các điều khoản này quy định rõ ràng cách dữ liệu được thu thập, lưu trữ, sử dụng và chia sẻ.
 - **Ý nghĩa:** Vi phạm ToS có thể dẫn đến việc tài khoản API bị khóa, cấm sử dụng các dịch vụ của Google hoặc thậm chí đối mặt với các hành động pháp lý. Cần đọc kỹ và đảm bảo mọi hoạt động thu thập và phân tích dữ liệu đều nằm trong khuôn khổ cho phép, ví dụ không được sao chép toàn bộ cơ sở dữ liệu bình luận hoặc sử dụng dữ liệu cho mục đích thương mại không được phép.
- **Ẩn danh thông tin nhận dạng cá nhân (PII) (Anonymization of PII):**
 - **Mô tả:** Bình luận trên YouTube có thể chứa thông tin nhận dạng cá nhân (PII) như tên người dùng, thông tin liên hệ, hoặc các chi tiết cá nhân khác do người dùng tự nguyện tiết lộ. Việc thu thập và xử lý các PII này mà không có sự đồng ý rõ ràng có thể vi phạm các luật bảo vệ dữ liệu như GDPR hoặc CCPA.
 - **Ý nghĩa:** Để bảo vệ quyền riêng tư của người dùng và tuân thủ pháp luật, cần phải ẩn danh hoặc loại bỏ mọi PII khỏi dữ liệu trước khi phân tích và chia sẻ. Điều này bao gồm việc không hiển thị tên người dùng gốc trong các báo cáo hoặc trực quan hóa, và chỉ tập trung vào nội dung bình luận đã được xử lý.
- **Không thu thập hoặc phân tích tin nhắn riêng tư (No Collection of Private Messages):**
 - **Mô tả:** YouTube có các tính năng nhắn tin riêng tư hoặc các kênh liên lạc không công khai khác. Dữ liệu từ các tính năng này không được phép thu thập hoặc phân tích dưới bất kỳ hình thức nào thông qua API công khai.
 - **Ý nghĩa:** Việc cố gắng truy cập hoặc phân tích tin nhắn riêng tư là một vi phạm nghiêm trọng về quyền riêng tư và có thể bị coi là hành vi bất hợp pháp. Mọi hoạt động phân tích chỉ nên giới hạn trong các bình luận công khai hoặc dữ liệu công khai khác được cung cấp thông qua API với các quyền truy cập phù hợp.

Tổng kết: Việc phân tích dữ liệu bình luận YouTube mang lại nhiều giá trị nhưng cũng đòi hỏi sự cẩn trọng cao độ đối với các rủi ro về chất lượng dữ liệu và tuân thủ pháp lý. Một chiến lược thu thập và xử lý dữ liệu chặt chẽ, minh bạch là cần thiết để đảm bảo tính toàn vẹn của nghiên cứu và bảo vệ quyền riêng tư của người dùng.

IV. KIỂM THỬ VÀ ĐÁNH GIÁ

4.1. Phân chia tập dữ liệu (Data Splitting)

Để đảm bảo tính khách quan trong việc đánh giá hiệu suất của mô hình phân tích cảm xúc (Sentiment Analysis), ta tiến hành phân chia tập dữ liệu World Cup và Olympics thành hai phần độc lập: tập huấn luyện (training set) và tập kiểm thử (test set).

Quá trình này được thực hiện thông qua thư viện `Scikit-learn` với các cấu hình cụ thể như sau:

- **Tỷ lệ phân chia:** 80:20 (80% dữ liệu dùng để huấn luyện mô hình và 20% dùng để kiểm thử độ chính xác).
- **Tính nhất quán (Reproducibility):** Việc thiết lập tham số `random_state=42` giúp đảm bảo tính nhất quán của dữ liệu đầu ra trong các lần chạy thử nghiệm khác nhau.
- **Xác định biến:**
 - Biến đầu vào (X): Cột văn bản đã làm sạch (`clean2`).

- Biến mục tiêu (y): Nhân cảm xúc (sentiment).

Bảng 5: Thống kê số lượng mẫu trong tập huấn luyện và kiểm thử

Bộ dữ liệu	Tập huấn luyện (Train)	Tập kiểm thử (Test)	Tổng cộng
World Cup	80	20	100
Olympics	80	20	100


Sau khi tiến hành huấn luyện và kiểm thử trên tập dữ liệu đã phân chia, chúng tôi sử dụng hai thước đo chính là **Độ chính xác (Accuracy)** và **Điểm F1 (F1-Score)** để đánh giá hiệu năng của mô hình phân loại cảm xúc. Kết quả thu được như sau:

Bảng 6: Kết quả đánh giá hiệu năng mô hình trên tập dữ liệu kiểm thử

Bộ dữ liệu	Độ chính xác (Accuracy)	Điểm F1 (F1-Score)
World Cup	0.7	0.5756
Olympics	0.9	0.8526

Phân tích kết quả:

- Đối với tập dữ liệu Olympics:** Mô hình hoạt động rất hiệu quả với độ chính xác đạt **90%** và điểm F1 đạt **0.8526**. Các chỉ số cao và đồng đều cho thấy mô hình có khả năng phân loại tốt và cân bằng giữa các lớp dữ liệu, ít xảy ra hiện tượng thiên lệch về một nhân cảm xúc cụ thể.
- Đối với tập dữ liệu World Cup:** Độ chính xác đạt mức khá (**70%**), tuy nhiên điểm F1 thấp hơn đáng kể (**0.5765**). Sự chênh lệch lớn giữa Accuracy và F1-Score gợi ý rằng:
 - Mô hình đang gặp khó khăn trong việc dự đoán các lớp thiểu số (imbalanced classes). Ví dụ: Nếu dữ liệu chủ yếu là bình luận tích cực, mô hình cứ đoán tất cả là "tích cực" thì Accuracy vẫn cao, nhưng F1 sẽ thấp do không nhận diện được bình luận tiêu cực.
 - Dữ liệu World Cup có thể chứa nhiều nhiễu (noise), tiếng lóng (slang) hoặc sarcasm (châm biếm) khó xử lý hơn so với Olympics.



Hình 18: So sánh Accuracy và F1-Score giữa WorldCup và Olympics

Nhận xét chung: Nhìn chung, mô hình đạt hiệu suất vượt trội trên dữ liệu Olympics. Đối với chủ đề World Cup, cần cải thiện thêm kỹ thuật tiền xử lý dữ liệu (như xử lý từ lóng, emoji) hoặc áp dụng các kỹ thuật cân bằng mẫu (như SMOTE hoặc Undersampling) để nâng cao điểm F1.

4.2. Khuyến nghị và đề xuất

4.2.1. Khuyến nghị cho ban tổ chức Olympics

Để tăng cường sự tham gia của khán giả và mức độ lan truyền cho Olympics 2024, dựa trên kết quả phân tích dữ liệu, nhóm nghiên cứu đề xuất các khuyến nghị cụ thể như sau:

1. Phát huy thế mạnh về cảm xúc tích cực:

- Tạo nội dung tôn vinh câu chuyện:** Tập trung kể những câu chuyện truyền cảm hứng về nỗ lực, sự kiên trì và thành công của các vận động viên, không chỉ người chiến thắng mà còn cả những người vượt qua thử thách. Nội dung này sẽ thúc đẩy cảm xúc *joy* (niềm vui) và *tears of joy* (nước mắt hạnh phúc).
- Khuyến khích chia sẻ khoảnh khắc cảm xúc:** Tổ chức các cuộc thi hoặc chiến dịch trên mạng xã hội yêu cầu khán giả chia sẻ khoảnh khắc cảm xúc nhất của họ (ví dụ: khi xem vận động viên yêu thích giành huy chương) kèm hashtag của Olympics.
- Tương tác với các bình luận tích cực:** Tăng cường trả lời, tương tác với các bình luận tích cực, đặc biệt là những bình luận khen ngợi hoặc bày tỏ sự ngưỡng mộ với các vận động viên.

2. Học hỏi từ World Cup về chủ đề lan tỏa mạnh mẽ:

- Tập trung vào vận động viên ngôi sao:** Dù Olympics không có một “Messi” duy nhất, hãy xác định và quảng bá các vận động viên có sức hút lớn, tạo nên những “khuôn mặt đại diện” cho từng môn thể thao. Xây dựng nội dung xung quanh hành trình, đối thủ và những khoảnh khắc quyết định của họ.
- Nhấn mạnh kịch tính và đối đầu:** Tạo ra các nội dung tiền sự kiện (pre-event) và trong sự kiện làm nổi bật các cuộc đối đầu lịch sử, những đối thủ truyền kiếp hoặc những kỷ lục có thể bị phá vỡ để tăng tính kịch tính.
- Nội dung dạng "Best moments" và "Emotional highlights":** Đăng tải thường xuyên các video tổng hợp những khoảnh khắc ấn tượng nhất, những pha thi đấu đỉnh cao và những khoảnh khắc cảm động để dễ dàng lan truyền (viral).

3. Chiến lược nội dung và tương tác để khuyến khích chia sẻ cảm xúc:

- Sử dụng Call-to-action (CTA) rõ ràng:** Trong các bài đăng và video, hãy khuyến khích khán giả bày tỏ cảm xúc bằng cách sử dụng các hashtag, emoji cụ thể hoặc để lại bình luận kể về cảm xúc của họ.
- Tổ chức Livestream Q&A với vận động viên:** Cho phép khán giả tương tác trực tiếp với các vận động viên, điều này thường tạo ra sự gắn kết và những khoảnh khắc chân thật.
- Gamification (Trò chơi hóa):** Tạo ra các cuộc thăm dò ý kiến, dự đoán kết quả hoặc các trò chơi nhỏ liên quan đến các môn thi đấu, khuyến khích người dùng chia sẻ kết quả.

4. Quản lý và chuyển hóa phản ứng tiêu cực:

- Tạo kênh phản hồi chính thức:** Cung cấp các kênh rõ ràng để khán giả gửi phản hồi, cho thấy ban tổ chức lắng nghe và quan tâm.
- Chuyển đổi thành nội dung giáo dục:** Đối với những bình luận tiêu cực liên quan đến quy tắc hoặc quyết định trọng tài, có thể tạo nội dung giải thích chuyên sâu để giáo dục khán giả và chuyển hướng cuộc thảo luận theo hướng tích cực hơn.
- Phản hồi chuyên nghiệp:** Đảm bảo đội ngũ quản lý mạng xã hội phản hồi các bình luận tiêu cực một cách chuyên nghiệp, không đối đầu.

5. Sử dụng hiệu quả Emoji và Meme trong truyền thông:

- Tạo bộ Emoji/Sticker độc quyền:** Thiết kế các emoji đặc trưng cho Olympics 2024 để khán giả sử dụng, giúp tăng nhận diện thương hiệu.
- Tận dụng Meme:** Theo dõi và tạo ra các meme hài hước hoặc lan truyền liên quan đến các

khoảnh khắc đáng nhớ (đảm bảo tính tôn trọng). Đây là công cụ mạnh mẽ để kết nối với khán giả trẻ (Gen Z).

- **Sử dụng Emoji chiến lược:** Tích hợp emoji vào các bài đăng chính thức để nội dung thân thiện và thể hiện cảm xúc rõ ràng hơn.

4.2.2. Đề xuất

Dựa trên toàn bộ kết quả phân tích chủ đề, cảm xúc và các xu hướng tương tác, phần này đưa ra các đề xuất chiến lược cụ thể cho marketing, quản trị khủng hoảng và dự báo xu hướng trong các sự kiện thể thao tương lai.

4.2.2.1. Tổng quan các kết quả phân tích

- **Phân bố cảm xúc:** Olympics 2024 có tỷ lệ cảm xúc tích cực cao hơn (**78%**) và tiêu cực thấp hơn (**14%**) so với World Cup 2022 (67% tích cực, 23% tiêu cực). Cả hai sự kiện đều cho thấy sự gắn kết cảm xúc mạnh mẽ từ khán giả.
- **Cường độ cảm xúc:** Biểu đồ phân phối điểm *compound sentiment* cho thấy cả hai sự kiện đều có một lượng lớn bình luận ở các cực tích cực và tiêu cực, chứng tỏ sự tham gia cảm xúc mạnh mẽ của người hâm mộ.
- **Xu hướng cảm xúc theo thời gian:** Biểu đồ xu hướng cảm xúc trung bình hàng ngày (năm 2025) cho thấy sự biến động, với World Cup có dao động mạnh hơn và đôi khi chạm đến vùng tiêu cực rõ rệt hơn so với Olympics.
- **Chủ đề thảo luận:**
 - *World Cup 2022:* Tập trung vào siêu sao (Messi, Ronaldo), đội tuyển (Argentina), kịch tính (final) và cảm xúc cực đoan (tears, trophy, skull).
 - *Olympics 2024:* Đa dạng hơn, bao gồm cảm xúc chung (joy, tears), nỗ lực (clapping, biceps), thành tích (gold, medal) và yếu tố quốc gia (India, France, Paris).
- **Mức độ viral:** World Cup 2022 vượt trội hoàn toàn so với Olympics 2024 về lượt xem, lượt thích và lượt bình luận (gấp khoảng 8.6, 4.75 và 15.6 lần tương ứng).

4.2.2.2. Chiến lược Marketing Mục tiêu: Tối đa hóa sự tham gia của khán giả, tăng cường phạm vi tiếp cận và chuyển đổi cảm xúc tích cực thành sự ủng hộ và tương tác.

a. Chiến lược Marketing

- **Khai thác cảm xúc:** Tạo chiến dịch UGC (User Generated Content) như "Khoảnh khắc tôi yêu", khuyến khích khán giả chia sẻ cảm xúc cá nhân để tận dụng tính kết nối cao của cộng đồng.
- **Đa dạng hóa nội dung:** Phân phối nội dung đa ngôn ngữ (đặc biệt là tiếng Pháp, tiếng Anh, tiếng Hindi...) và bản địa hóa văn hóa để tiếp cận tối đa lượng fan toàn cầu.
- **Tối ưu hóa Emoji & Meme:** Thiết kế bộ Sticker/Emoji độc quyền cho sự kiện và tận dụng văn hóa Meme hài hước, văn minh để tiếp cận và tăng tương tác với nhóm khán giả trẻ (Gen Z).

b. Quản trị Khủng hoảng

- **Giám sát thời gian thực:** Thiết lập hệ thống theo dõi sentiment để phát hiện sớm các từ khóa cực đoan (ví dụ: emoji :skull:) giúp nhận diện khủng hoảng ngay khi mới manh nha.
- **Phản ứng nhanh và minh bạch:** Đội ngũ truyền thông cần cung cấp thông tin chính xác và phản hồi chuyên nghiệp ngay khi có tranh cãi, tránh sự im lặng làm tăng phần nộ.
- **Xử lý nhiễu:** Sử dụng công cụ lọc bot/spam để đảm bảo luồng thảo luận không bị thao túng bởi các tác nhân bên ngoài.

c. Dự báo Xu hướng trong tương lai

- **Phân tích sự thay đổi chủ đề (Topic Evolution):** Áp dụng Topic Modeling định kỳ để theo dõi sự dịch chuyển mối quan tâm của khán giả qua các giai đoạn (trước, trong và sau sự kiện).
- **Tích hợp đa nguồn dữ liệu:** Kết hợp dữ liệu YouTube với Twitter, Facebook và báo chí để có cái nhìn toàn diện 360 độ về xu hướng thị trường.
- **Định hướng nội dung:** Dựa trên dữ liệu dự báo để lên kế hoạch sản xuất nội dung trước cho các kịch bản tiềm năng (kỷ lục mới, tranh cãi, ngôi sao mới nổi).

4.2.2.3. Học hỏi từ World Cup về chủ đề lan tỏa mạnh mẽ

- **Nhấn mạnh vào cá nhân/đội tuyển ngôi sao:** Xác định và quảng bá các vận động viên Olympics có sức hút lớn (tương tự hiệu ứng Messi/Ronaldo), tạo hồ sơ chuyên sâu về họ.
- **Tạo nội dung kịch tính và đối đầu:** Xây dựng video highlight tập trung vào các cuộc đối đầu gay cấn hoặc kỷ lục bị phá vỡ. Tận dụng emoji cảm xúc mạnh như *:fire:*, *:boom:*.
- **Phân phối đa ngôn ngữ và khu vực:** Bản địa hóa nội dung cho các quốc gia có lượng fan lớn (ví dụ: Ấn Độ, Pháp) để tối ưu hóa phạm vi tiếp cận.

4.2.2.4. Sử dụng hiệu quả Emoji và Meme

- **Bộ Emoji/Sticker độc quyền:** Thiết kế sticker riêng cho sự kiện để tăng nhận diện thương hiệu.
- **Tận dụng xu hướng Meme:** Tạo meme hài hước, văn minh để kết nối với khán giả trẻ (Gen Z).

4.2.2.5. Quản trị Khủng hoảng (Crisis Management) Mục tiêu: Giảm thiểu tác động tiêu cực và duy trì hình ảnh tích cực.

- **Giám sát cảm xúc liên tục (Real-time Monitoring):** Thiết lập hệ thống theo dõi sentiment thời gian thực để phát hiện sớm các từ khóa cực đoan (ví dụ: *:skull:*, *:crossbones:*).
- **Phản ứng nhanh và minh bạch:** Cung cấp thông tin chính xác ngay khi có tranh cãi, tránh sự im lặng làm tăng phần nộ.
- **Chuyển hóa tiêu cực thành cơ hội:** Dùng nội dung giáo dục/phân tích chuyên môn để giải thích các tranh cãi về trọng tài hoặc quy tắc, hướng thảo luận về tính chuyên nghiệp.
- **Xử lý nhiễu (Spam/Bot):** Sử dụng công cụ lọc bot/spam để đảm bảo luồng thảo luận không bị thao túng.

4.2.2.5. Dự báo Xu hướng trong các sự kiện thể thao tương lai Mục tiêu: Sử dụng dữ liệu hiện có để tối ưu hóa chiến lược cho các sự kiện sắp tới.

- **Phân tích sự thay đổi chủ đề (Topic Evolution):** Áp dụng Topic Modeling định kỳ để theo dõi sự dịch chuyển mối quan tâm (ví dụ: từ khóa "2025" xuất hiện trong World Cup gợi ý sự quan tâm đến tương lai).
- **Mô hình hóa cảm xúc và tương tác:** Xây dựng mô hình dự đoán mức độ viral dựa trên dữ liệu lịch sử (vận động viên, thời điểm đăng, loại nội dung).
- **Tích hợp đa nguồn dữ liệu:** Kết hợp dữ liệu YouTube với Twitter, Facebook và báo chí để có cái nhìn toàn diện 360 độ.
- **Định hướng nội dung theo dự báo:** Lên kế hoạch sản xuất nội dung trước cho các kịch bản tiềm năng (kỷ lục mới, tranh cãi, ngôi sao mới nổi).

V. KẾT LUẬN.

Kết quả phân tích cho thấy, cả hai sự kiện thể thao toàn cầu — *Olympics 2024* và *World Cup 2022* — đều thu hút sự quan tâm mạnh mẽ từ công chúng, với tỷ lệ cảm xúc tích cực chiếm ưu thế. Tuy nhiên, Olympic 2024 nổi bật hơn với mức độ cảm xúc lạc quan và đa dạng hơn, phản ánh tinh thần thể thao, sự tự hào dân tộc và giá trị nhân văn được lan tỏa sâu rộng. Trong khi đó, World Cup 2022 ghi nhận mức độ tương tác cao hơn

nhưng cũng đi kèm với tỷ lệ tiêu cực lớn hơn, cho thấy sức hút của bóng đá toàn cầu luôn đi cùng những tranh luận và cảm xúc trái chiều. Tổng thể, kết quả nghiên cứu đã minh chứng rằng các sự kiện thể thao quốc tế không chỉ là hoạt động thi đấu mà còn là hiện tượng truyền thông xã hội mang tính toàn cầu, phản ánh rõ nét tâm lý và xu hướng quan tâm của cộng đồng mạng. Kết quả phân tích cho thấy cả World Cup 2022 và Olympics 2024 đều chia sẻ những điểm tương đồng sâu sắc về mặt cảm xúc và chủ đề thảo luận. Cả hai sự kiện đều kích thích những phản ứng mạnh mẽ từ cộng đồng, thể hiện qua sự xuất hiện dày đặc của các từ khóa cảm xúc như *joy*, *tears*, *crying* cùng các biểu tượng cảm xúc (emoji) mang tính ăn mừng như :red hay :popper. Các chủ đề về chiến thắng và thành tích luôn chiếm ưu thế, dù là khoảnh khắc nâng cúp của Argentina hay những tấm huy chương vàng tại Olympics.

Tuy nhiên, sự khác biệt giữa hai sự kiện lại vô cùng rõ rệt ở mức độ lan tỏa và sắc thái cảm xúc:

- **Về mức độ Viral:** World Cup 2022 chứng tỏ sức hút vượt trội với lượng tương tác (view, like, comment) áp đảo hoàn toàn so với Olympics 2024, khẳng định khả năng duy trì sự chú ý tốt hơn của môn thể thao vua.
- **Về phân bố cảm xúc:** Olympics 2024 ghi nhận tỷ lệ cảm xúc tích cực cao hơn (**78%**) so với World Cup (**67%**). Ngược lại, World Cup có tỷ lệ tiêu cực cao hơn (**23%** so với **14%** của Olympics), phản ánh tính chất cạnh tranh gay gắt và các tranh cãi thường thấy trong bóng đá.
- **Về chủ đề thảo luận:** Nếu World Cup xoay quanh các cá nhân "siêu sao" (Messi, Ronaldo) và kịch tính trận chung kết, thì Olympics mang tính đa dạng hóa hơn với sự quan tâm dành cho nhiều quốc gia (India, France) và các vận động viên khác nhau, không quá phụ thuộc vào một cá nhân duy nhất.